

Kaggle 巴西olist電商數據分析期末書面報告

1. 背景與研究動機 (Why?)

本專案的研究動機主要來自於個人對資料分析實務能力的培養與驗證。為提升自己在電商領域的分析能力，本專案以「模擬電商平台數據分析師」為出發點，參考 CRM、CLV 與 STP 等相關理論與概念，盤點電商平台在顧客經營上常見的分析議題，並將其收斂為核心問題，再進一步拆解為可執行的子目標。最後，透過資料科學與數據探勘方法建立可重現的分析流程，產出可用於決策支援的模型結果與策略建議。

2. 專案目標 (What?)

為確保本專案從商業需求出發並具備可衡量的完成標準，本研究將專案目標分為三個層次：(1)「業務核心目標與拆解」用以界定決策者關心的商業問題，並將其轉化為可執行的分析任務；(2)「商業成功指標」用以定義專案成果在業務上是否可用，避免僅完成分析卻無法支持決策；(3)「模型目標」則進一步具體化資料探勘任務的建模方法、預期輸出與技術驗證標準，使分析流程可被評估、可被重現。上述架構之設定亦具備理論依據與商業合理性：首先，顧客留存研究指出，提高留存率將對企業獲利帶來顯著影響，且維持既有顧客的成本通常低於獲取新顧客，因此企業在資源有限的情境下，應優先將經營重點放在具高貢獻潛力之顧客群，以降低其流失風險並提升整體顧客資產價值。其次，依據顧客生命週期與顧客終身價值（CLV）理論，顧客價值會隨關係成熟而遞增，而流失代表生命週期被提前終止，使未來可實現的收益無法回收；因此本專案需先建立可量化的顧客價值指標，將「高價值顧客」轉化為可分析對象，並進一步建立流失定義與預測模型，以辨識高風險流失顧客、支援挽留決策。最後，由於顧客價值具有高度異質性，若缺乏分群與價值衡量機制，行銷資源將被迫平均投放而導致效率低落；故本研究採用分群方法描繪不同顧客族群的行為輪廓，並將模型輸出轉譯為可執行的策略建議，以落實差異化顧客經營與精準行銷決策。

2.1 核心業務目標: 辨識高價值顧客，並降低其流失風險

2.2 業務核心目標拆解: 由核心目標進行業務子目標拆解

- 定義顧客價值: 把高價值顧客變成可量化可定義，否則後續分群、預測、策略都會失去依據
- 建立顧客價值分群: 用LTV RFM特徵做分群
- 描述高價值顧客行為輪廓: 產生出高價值顧客的5-10條行為特徵描述
- 顧客流失定義: 定義清楚什麼是流失顧客
- 建構模型預測顧客流失: 產出流失機率名單、高風險顧客名單
- 找出影響高價值顧客流失的關鍵因素:
- 提出可落地的行銷策略: 將發現的知識轉成企業能落地的行動

2.3 商業成功指標

- 完成流失定義，且能輸出可下發的高風險名單（Top N + 機率 + 原因）
- 能夠將客戶進行分群，群間GMV / LTV 差異有統計顯著性
- 辨識出至少三項可應用於行銷策略的分析洞察
- 至少提出 3 套可落地策略，且每套策略都能對應預期 KPI 與驗證方式



example:

對「快流失的高價值客」發優惠券喚回

- 期待結果（KPI）：**30 天回購率↑、流失率↓**
- 怎麼驗證：**一半人發券、一半人不發**，看哪一半回購比較多（A/B test）

2.4 模型目標

a. 顧客價值分析

- 使用 RFM、K-means 分群，將顧客依價值劃分為不同群組
- 輸出: 高、中、低價值客戶群、不同群組的行為輪廓（購買頻率／金額／配送品質等）
- 成功指標: 分群模型 Silhouette ≥ 0.3

b. 顧客流失分析

- 納入RFM指標做為input features
- 找出輸入模型的關鍵特徵
- 建立顧客流失預測模型（例如 Random Forest），找出影響流失的關鍵變數
- 輸出: 影響因子重要性排行、高價值客戶流失機率名單
- 成功指標: 流失預測模型 F1-score $\geq$ **0.6–0.7**

c. 高價值顧客行銷策略


- 使用apriori模型，找出高價值顧客的偏好、常購品項組合、回購邏輯。
- 輸出: 商品關聯規則、高價值顧客行為特徵、精準行銷策略建議
- 成功指標1: Apriori 至少產生 5 組顯著規則 (Lift > 1)
- 成功指標2: 高價值顧客的行為模式可被清楚解釋
- 成功指標3: 策略可以被落地實施

3. 分析方法 (How?)

本專案採用 CRISP-DM（Cross-Industry Standard Process for Data Mining）作為整體分析流程架構。CRISP-DM 為業界常用之資料科學專案方法論，強調從商業理解出發，逐步進行資料理解、資料準備、建模、評估與部署，確保分析成果能夠回應實際業務需求。

透過 CRISP-DM 的流程設計，本研究得以在專案初期即明確定義商業問題與成功指標，避免分析方向偏離業務目標；同時，也能在後續分析階段清楚區分不同任務的產出與限制，提升整體專案的結構性與可解釋性。

圖 1. 資料採礦生命週期



3.1 Data understanding

本階段的目的為，在建構模型前先完整地掌握資料的結構、粒度、品質與限制並且評估此資料是否能夠支援既定的業務問題與資料探勘目標。同時在探索過程中形成對資料中可能存在的關聯與模式做初步假設，為後續資料準備、特徵工程、建構模型提供重要依據。

首先我先在此方法區分靜態理解與動態探索。



先做靜態探索 (盤點、欄位、粒度關聯)，確保資料可以使用，並且為後續分析提供基礎，再做動態探索(EDA / 可行性分析)形成假設與分析風險評估。

步驟	產出	靜態理解/動態探索	完成？
資料盤點	table inventory	靜態理解	已完成
欄位盤點	column inventory	靜態理解	已完成
粒度與關聯檢查	ER / 粒度說明	靜態理解	進行中

步驟	產出	靜態理解/動態探索	完成？
資料品質報告	quality report	靜態理解	未完成
探索性資料分析	notebook 圖表	動態探索	未完成
可行性評估	文字結論	動態探索	未完成

3.1.1 資料盤點 (Data Inventory) (已完成)

在資料理解階段，首先進行資料盤點 (Data Inventory)，以全面掌握本專案所使用資料的來源、規模與時間範圍。本專案採用 Kaggle 所提供之 Olist 電商資料集，資料內容涵蓋顧客、訂單、訂單明細、賣價、付款、物流、商品、顧客評價等多個面向。透過資料盤點，本研究整理出各資料表之筆數 (row)、欄位數 (columns)、資料期間，並確認資料涵蓋完整的交易生命週期，可支援後續顧客價值與行為分析需求。

	table_name	row_count	column_count
0	translation	71	2
1	sellers	3095	4
2	product	32951	9
3	orders	99441	8
4	order_review	99224	7
5	order_payment	103886	5
6	order_items	112650	7
7	geolocation	1000163	5
8	customer	99441	5

交易資料生命週期



本階段之盤點結果顯示，資料在時間跨度與交易完整性上具備基本分析可行性，適合作為後續顧客層級分析的資料基礎。

3.1.2 欄位盤點與商業意義 (Column Inventory, 靜態理解) (已完成)

在完成資料表層級盤點後，本專案進一步進行欄位盤點 (Column Inventory)，針對各資料表中之欄位進行整理與分類，包含欄位名稱、資料型態、商業意義以及其在分析中的角色。

為支援後續分析目標，本研究逐利用python整理column inventory 表，整理包括：(table name、column_name、dtype、row_count、null_count、null_rate、n_unique、sample_values、unique_list)然後使用excel添加欄位business meaning逐一檢查每一個欄位到底對應什麼樣的商業意義。

欄位盤點結果作為後續特徵工程與分析指標定義的重要依據，亦有助於避免在建模階段誤用或誤解欄位意義。

已完成檔案: [column_inventory.csv](#)

3.1.3 欄位粒度與關聯盤點 (Relationship & Grain, 靜態理解) (進行中)

在完成資料盤點與欄位盤點後，下一步將進行資料表之間的關聯與粒度檢查。本專案後續分析之核心粒度預計設定為顧客層級，因此需要釐清各個資料表的自然粒度(如:訂單層級、商品層級)，以及其與顧客表的關聯方式。

在此階段，將透過主鍵與外鍵欄位檢查、資料列數變化觀察，以及實際 join 測試，驗證資料表之間的一對一或一對多關係是否符合商業邏輯，並評估資料整併後可能產生的重複列風險。

目前本階段尚在規劃與執行中，相關結果將作為後續建構顧客層級分析資料集的重要依據。

3.1.4 資料品質評估 (Data Quality Assessment, 靜態理解) (尚未完成)

為確保後續分析結果之可靠性，資料品質評估將作為資料理解階段的重要環節。預計將針對關鍵欄位進行缺失值比例、異常值分佈與資料一致性檢查，例如交易金額是否存在不合理數值、時間欄位是否符合事件發生順序等。

透過資料品質評估，將可及早辨識可能影響分析結果的資料問題，並據此制定對應的資料處理策略。此階段尚未正式完成，將於後續資料準備階段一併處理。

3.1.5 探索性資料分析 (EDA, 動態探索) (尚未完成)

本專案之探索性資料分析（EDA）屬於 Data Understanding 階段的「動態探索」，採用問題導向的方式進行。亦即在執行任何圖表與統計檢查前，先定義 EDA 必須回答的核心問題，並依問題拆解設計對應的探索步驟與產出。

本研究將 EDA 聚焦於三大問題：

- (1) 資料行為是否合理（時間、金額、狀態是否符合商業直覺）
- (2) 顧客是否存在明顯異質性（價值是否集中、特徵是否具區辨度）
- (3) 是否存在可供後續分群與流失預測使用的訊號（流失定義可行性與候選特徵）

本階段僅進行描述性統計與探索性彙總，以形成假設、確認可行性並辨識分析風險；正式特徵工程與建模資料集將於 Data Preparation 階段完成。

問題1: 資料行為是否合理？

為確保後續 RFM、流失定義與策略分析具備可靠基礎，本專案將從時間、金額與狀態三方面進行檢查：

1. 時間軸合理性

- 檢查項目：訂單數與活躍顧客數是否存在異常斷點或劇烈波動
- 方法：以 orders 的下單時間進行日/週趨勢視覺化與缺口檢查
- 產出：確認可用資料期間與可能需排除的時間段

2. 金額與訂單量合理性

- 檢查項目：金額是否高度偏態、是否存在極端異常值
- 方法：以 order_items 金額彙總為探索性 GMV proxy，檢視分位數與長尾分布
- 產出：提出後續是否需進行極端值處理（如 winsorize/clip）的依據（正式處理留到 Data Preparation）

3. 訂單狀態與缺失對分析的影響

- 檢查項目：取消/不可用訂單比例、不同狀態下時間欄位缺失是否具系統性
- 方法：比較 order_status 分布與各狀態之交付時間缺失率
- 產出：訂定後續分析口徑（例如 LTV 是否僅納入 delivered 訂單、流失定義是否排除 canceled）

問題二: 顧客價值是否存在明顯差異？

本專案以顧客層級彙總觀察顧客價值的集中程度與可區辨性：

1. 是否存在帕累托現象

- 方法：計算顧客累積貢獻（訂單數或 GMV proxy）之 Top 10%/20% 占比
- 產出：判斷顧客價值是否高度集中，支持「高價值顧客」經營的必要性

2. R/F/M分布是否具區辨度

- 方法：以 orders 進行顧客層級彙總，觀察最近購買時間與訂單數分布
- 產出：評估 RFM 是否能有效拉開顧客差異，作為後續分群特徵設計的依據

3. 高價值顧客行為輪廓候選變數是否有差

- 方法：先以簡化價值（例如 GMV 或訂單數分位數）將顧客粗分高/非高價值兩群，比較候選行為指標（配送延遲、評分、品類多樣性等）之分布差異
- 產出：篩選可用於「高價值顧客行為輪廓」的特徵候選清單（正式定義留到後續階段）

問題三: 是否存在可被建模利用的訊號?

1. 以購買行為定義流失是否合理（時間窗探索）

- 方法：分析顧客回購間隔分布與活躍衰退情形，作為觀察窗/預測窗設計依據
- 產出：提出流失定義的時間尺度建議（例如 N 天未購買視為流失）

2. 流失是否與可觀測體驗相關（關聯探索）

- 方法：比較不同配送延遲/評分區間之再購行為差異（僅作關聯探索，不進行因果推論）
- 產出：候選特徵（如 delivery_delay、low_score_flag）與初步假設

3. 行銷策略所需購物籃訊號是否足夠

- 方法：觀察品類集中度、購物籃大小、重複購買品類等分布
- 產出：判斷是否值得進一步執行 Apriori，並提供支援度/門檻設定的初步依據

3.1.6 分析可行性與限制評估 (尚未完成)

在資料理解階段，亦需同步評估資料對於研究目標的支援程度與限制。本專案所使用資料以交易行為為主，未包含行銷曝光、促銷活動或顧客接觸點資料，因此分析重點將聚焦於顧客行為關聯與預測，而非行銷活動的因果推論。

因此，本專案之分析定位為「決策支援型分析」，旨在協助企業辨識高價值顧客與潛在流失風險，並提供行銷策略設計的參考依據，而非直接評估行銷活動成效

3.2 Data preparation (尚未完成)

本階段目的在於：將原始多表交易資料整理成可分析、可建模的資料集。核心做法是先確立分析粒度與口徑，再完成清理與彙總整併，最後產出分群與流失預測所需的分析資料集，確保後續模型使用的資料一致且可重現。

本階段做法

3.2.1 定義口徑與粒度

- 明確分析粒度（顧客層級為主）與使用範圍（例如是否僅納入 delivered 訂單、金額是否含運費等）。

3.2.2 資料清理與型態統一

- 統一時間欄位型態、金額欄位型態，並依缺失與異常情境建立處理規則。

3.2.3 先彙總再整併（避免資料重複計算）

- item/payment/review 等多筆事件表先彙總到訂單層級，再併回 orders，最後再彙總到顧客層級。

3.2.4 建立分析資料集

- 分群用：建立顧客層級 ABT（每位顧客一筆彙總特徵）。
- 流失用：建立顧客×時間快照的 panel dataset（包含觀察窗特徵與預測窗標籤）。

主要產出

- 指標口徑與特徵定義（文字或清單）
- 顧客層級 ABT（分群用）
- 流失 panel dataset（預測用）
- 時間切分規則（避免資料洩漏）

3.3 Modeling (尚未完成)

本階段目的在於：依照專案目標建立可用於決策支援的模型輸出，包含顧客價值分群、顧客流失預測，以及高價值顧客的策略規則挖掘。模型重點不僅在準確度，也包含可解釋性與可落地性，以支援後續行銷與顧客經營決策。

3.3.1 顧客價值分群 (RFM + K-means)

怎麼做：以 R/F/M (及必要的可解釋行為特徵) 作為分群特徵，進行標準化後訓練 K-means，並以群組輪廓解釋與命名各群 (高/中/低價值或策略族群)。

產出：顧客分群標籤、各群行為輪廓摘要、分群品質指標 (如 silhouette)。

3.3.2 高價值顧客流失預測 (以 Random Forest 為主)

怎麼做：先定義流失標籤 (以預測窗是否再購)，再以觀察窗特徵訓練模型，採時間切分評估並輸出高風險名單與關鍵影響因子。

產出：流失機率、風險名單 (top-k 或門檻)、特徵重要性/影響因子排序、模型評估指標 (如 F1)。

3.3.3 高價值顧客策略挖掘 (Apriori 關聯規則)

怎麼做：以高價值顧客之訂單作為購物籃，建立商品/品類共現資料後執行 Apriori，篩選具商業意義之規則並轉譯為行銷策略。

產出：關聯規則清單 (support/confidence/lift)、對應可落地策略 (加購、組合、推薦、再行銷)。

3.4 Evaluation (尚未完成)

本階段目的在於：從技術與商業兩個角度檢驗本專案的分析結果是否可信、是否可用於決策支援，並確認模型/分群是否達到既定成功指標。同時針對可能的風險 (資料偏誤、資料洩漏、口徑不一致) 進行檢查，確保結論具備可解釋性與可落地性。

本階段做法

1. 分群結果評估

- 檢查分群品質 (如 silhouette、群大小是否合理)。
- 驗證群間差異是否明顯 (例如 GMV/LTV、訂單數、回購行為等群間比較)。
- 確認群組可解釋 (能否用 5-10 條輪廓描述、是否能映射到策略)。

2. 流失模型評估

- 以時間切分的 test set 評估模型表現 (F1、precision/recall 等)。
- 檢查高風險名單品質 (例如 top-k 的 precision、能否對應可行的挽留策略)。
- 檢視特徵重要性與合理性 (是否符合商業直覺、是否疑似資料洩漏)。

3. 策略可行性評估

- 檢查輸出是否能轉化為行動 (哪些客群要做什麼、預期效果是什麼)。
- 明確列出限制與假設 (資料缺口、不可做因果推論等)。

3.5 Deployment (尚未完成)

本階段目的在於：將分析成果以可重現、可交付的形式輸出，讓決策者或使用者可以理解、使用並持續更新。本專案之部署以「決策支援」為定位，重點在於提供可視覺化的結果呈現、可執行的名單輸出，以及可重跑的分析流程，而非將模型直接上線到線上系統。

本階段做法

1. 結果交付與視覺化

- 製作儀表板或報表 (例如分群分布、群組輪廓、流失風險名單概況、關鍵因子)。
- 將結論整理成可直接採用的策略建議 (對象、動作、理由、指標)。

2. 名單與規則輸出

- 輸出高價值顧客名單、流失高風險名單 (含機率或排序)。
- 輸出商品關聯規則與對應行銷情境 (加購/組合/推薦)。

3. 可重現流程與文件化

- 將資料處理、特徵、模型訓練流程整理為 notebook / script，並記錄版本與參數。
- 彙整成「專案文件」與「使用說明」 (如何更新資料與重新產出結果)。

4. 專案進度說明 (Progress)

本專案採用 CRISP-DM 作為方法論，並依照階段產出進行專案管理。目前已完成 Business Understanding 與部分 Data Understanding（資料盤點、欄位盤點），其餘階段仍在進行中。以下整理各階段之目前完成度與下一步工作項目。

CRISP-DM 階段	項目	目前狀態	已完成產出
Business Understanding	目標、指標、方法選擇	已完成	研究動機、目標拆解、成功指標
Data Understanding	靜態理解	部分完成	table inventory、column inventory、生命週期描述
Data Understanding	動態探索（EDA）	規劃中	EDA 問題框架
Data Preparation	清理、彙總、建 ABT	未開始	—
Modeling	分群、流失、規則	未開始	—
Evaluation	技術+商業驗證	未開始	—
Deployment	交付與文件化	未開始	—

5. 理論參考文獻

本專案之理論基礎主要來自顧客留存（Retention）、顧客終身價值（CLV）、顧客價值異質性與分群（Segmentation/Value Heterogeneity）等領域之經典研究。相關理論提供本研究「為何要留存高價值顧客」以及「為何需要分群與流失預警」的學理依據，並作為指標設計與分析方法選擇的出發點

5.2 顧客生命週期與顧客終身價值（Customer Life Cycle & CLV）

Gupta & Lehmann (2003)

- 核心概念：CLV 作為衡量顧客在其生命週期中可為企業帶來的長期價值之指標，可用於資源配置與顧客經營決策。
- 本研究引用目的：支撐本專案以「顧客終身價值提升」作為最終商業目標。

Reinartz & Kumar (2000)

- 核心概念：顧客關係與價值具有差異，顧客價值管理需以資料與分層經營支撐，而非一體適用。
- 本研究引用目的：支撐分群與差異化策略的必要性。

顧客生命週期（概念模型）

- Acquisition（取得）→ Development（發展）→ Retention/Loyalty（留存）→ Churn（流失）
- 本研究引用目的：用於說明「流失」等同於生命週期被提前終止，造成未來收益無法實現。

5.3 顧客價值異質性與未差異化行銷（Value Heterogeneity & Undifferentiated Marketing）

- 核心概念：顧客價值分布常呈現高度偏態，少數顧客貢獻多數價值，若企業未辨識差異並分層經營，將導致資源平均投放、效率低落。
- 對應實務問題：EDM 全客戶同推、折扣碼無差別、再行銷名單不分層、客服關懷無優先序等。
- 本研究引用目的：支撐本專案「先辨識高價值顧客 → 再做分群 → 再做流失預警」的策略路徑。

5.4 帕累托法則（Pareto Principle）

- 核心概念：多數情況下，結果常由少數關鍵因素驅動（常以 80/20 作為經驗描述，不必固定比例）。
- 本研究引用目的：支持「顧客價值集中」的直覺假設，並作為 EDA 檢查（是否存在價值集中現象）與分群必要性之理論背景。

參考文獻

- Reichheld, F. F., & Sasser, W. E. (1990). *Zero Defections: Quality Comes to Services*. Harvard Business Review.
- Reinartz, W., & Kumar, V. (2000). *On the profitability of long-life customers in a noncontractual setting: An empirical investigation and implications for marketing*. Journal of Marketing.
- Gupta, S., & Lehmann, D. R. (2003). *Customers as assets*. Journal of Interactive Marketing.